

Construcción del Dataset

Para el desarrollo del modelo de predicción del precio de la papa se consideraron las siguientes variables:

- **Precio promedio por kilogramo:** corresponde a la variable objetivo del modelo y representa el historial de precios de las diferentes variedades de papa comercializadas en el mercado mayorista.
- **Variedad de papa:** permite identificar la variedad específica a la que pertenece cada registro de precio, ya que cada una presenta un comportamiento de mercado diferente.
- **Volumen de abastecimiento:** representa la cantidad de papa ingresada al mercado mayorista por variedad y constituye un indicador de la oferta disponible.
- **Zona abastecedora:** identifica la región y zona de procedencia de la papa, permitiendo relacionar el comportamiento de los precios con el origen de producción.
- **Índice del precio del diésel:** se incorpora como un indicador indirecto de los costos de transporte. Las variaciones del precio del combustible influyen en el costo del traslado de la papa hacia Lima Metropolitana, afectando finalmente su precio de venta.
- **Nivel de precipitación:** representa la cantidad de lluvia registrada en cada zona abastecedora. Esta variable puede influir en las condiciones de las carreteras y, por consiguiente, en los tiempos de transporte de los productos agrícolas.
- **Días con helada durante el cultivo:** cuantifica el número de días con presencia de heladas durante el periodo de cultivo de la papa. Las heladas pueden afectar el rendimiento y la calidad del cultivo, repercutiendo posteriormente en el precio del producto.
- **Temperatura mínima:** permite identificar la ocurrencia de heladas y sirve como base para el cálculo de la variable *días con helada durante el cultivo*.

Fuentes de información:

Para obtener las variables descritas anteriormente se utilizaron tres fuentes oficiales de información:

- **BCRP Data:** proporciona los índices reales de precios del petróleo diésel. Aunque no representa el precio comercial del combustible, este indicador permite medir las variaciones relativas del costo del diésel a lo largo del tiempo.
- **SISAP V2:** suministra la información correspondiente al precio promedio por kilogramo, volumen de abastecimiento, variedades de papa y zonas de procedencia de los productos comercializados en el mercado mayorista de Lima Metropolitana.
- **NASA POWER:** proporciona información climática diaria para cada una de las zonas abastecedoras, incluyendo temperatura mínima, temperatura máxima, temperatura promedio y precipitación.

Proceso de recolección de datos:

BCRP Data

Para obtener los índices reales del precio del diésel se realizaron los siguientes pasos:

1. Ingresar al portal de estadísticas del BCRP.
2. Seleccionar la sección **Precios y tarifas**.
3. Acceder a **Índices reales de precios de combustibles y tarifas**.
4. Seleccionar **Precio de Combustibles – Petróleo Diésel**.
5. Descargar la serie en formato CSV.

El archivo descargado posee un nombre con el formato **Mensuales-xxxx-xxxx.csv**, el cual varía según la fecha de descarga.

NASA POWER

Para obtener la información climática se siguió el siguiente procedimiento:

1. Ingresar al portal NASA POWER.
2. Seleccionar **Data Access Viewer**.

3. Elegir la modalidad **Single Point**.
4. Configurar **Standard Resolution**.
5. Seleccionar la comunidad **AgroClimatology**.
6. Escoger el nivel temporal **Daily**.
7. Ingresar las coordenadas geográficas (latitud y longitud) correspondientes a cada zona abastecedora descrita en el Anexo A.
8. Definir el intervalo de fechas desde el **01/08/2021** hasta el **23/05/2026**.
9. Seleccionar las variables:
 - Temperature at 2 meters
 - Temperature at 2 meters Minimum
 - Temperature at 2 meters Maximum
 - Precipitation (IMERG)
10. En **Advanced Parameters**, cambiar el estándar horario de **LST** a **UTC**.
11. Seleccionar el formato de descarga **CSV**.
12. Descargar el archivo.

Este procedimiento se repitió para todas las zonas abastecedoras incluidas en el estudio.

SISAP V2

Precio promedio por kilogramo

Para obtener los precios promedio se siguieron los siguientes pasos:

1. Ingresar al portal SISAP.
2. Seleccionar el mercado **Papa**.
3. Elegir la opción **Precio Promedio**.
4. Consultar dos intervalos de tiempo:
 - 01/01/2021 – 23/12/2023
 - 01/01/2024 – 23/05/2026
5. Ejecutar la consulta.
6. Seleccionar **Herramientas**.

7. Exportar la información en formato Excel.

Volumen de abastecimiento

Para obtener el volumen de abastecimiento por departamento se siguieron los siguientes pasos:

1. Ingresar al portal SISAP.
2. Seleccionar el mercado **Papa**.
3. Elegir la opción **Volumen**.
4. Seleccionar cada uno de los departamentos con información disponible.
5. Consultar los mismos dos intervalos de tiempo utilizados para los precios.
6. Ejecutar la consulta.
7. Exportar los resultados en formato Excel.

Primer procesamiento de datos:

Índice del diésel:

Se utilizó el notebook **Preprocesar_diesel.ipynb**, cuyo objetivo fue transformar el formato original del archivo descargado del BCRP (por ejemplo, **Ene10**) a un formato de fecha estándar (**2010-01-01**), compatible con el resto de los conjuntos de datos.

Como resultado se generó el archivo: **indicadores_diesel_limpio.csv**

Precios:

Se utilizó el programa **Transformar_precio.py** para convertir el archivo Excel exportados desde SISAP a formato CSV y estructurar adecuadamente la información correspondiente al precio promedio por kilogramo según fecha y variedad de papa.

Como resultado se obtuvo: **dataset_precios.csv**

Se utilizó después el notebook **Precios_preprocesamiento.ipynb** para limpiar el formato si es que hubo errores al momento de convertir el nuevo formato .csv de **dataset_precios.csv**

Como resultado se obtuvo: **dataset_preprocesado_precios.csv**

Volumen de abastecimiento:

El procesamiento del volumen se realizó mediante tres programas ejecutados de forma secuencial:

1. **Transformar_Volumen.py:** convierte los archivos Excel descargados desde SISAP a formato CSV.
2. **Fusionar_Datasets.py:** consolida los dos archivos correspondientes a cada departamento en un único archivo.
3. **Unir_Datasets_Volumen.py:** integra los archivos consolidados de todos los departamentos en un único conjunto de datos ordenado por fecha, variedad, región y zona.

El resultado final fue: **dataset_unificado_volumen_total.csv**

Información climática:

El procesamiento de la información climática se realizó mediante el programa **Unir_Zonas_Clima.py**.

Este programa:

- limpia los archivos descargados desde NASA POWER;
- integra la información de todas las zonas abastecedoras;
- calcula la variable **días_con_helada_en_cultivo**;
- elimina los registros para los cuales no es posible calcular dicha variable.

Como resultado se obtuvo un conjunto de datos comprendido entre el **01/01/2022** y el **23/05/2026**.

El archivo generado fue: **Consolidado_Clima_Zonas.csv**

Segundo procesamiento de datos:

El conjunto de datos final se obtuvo mediante tres notebooks ejecutados de forma consecutiva.

1. Consolidar_Precios_Volumen.ipynb

Se realizó una unión (*merge*) entre el conjunto de datos de precios y el de volumen utilizando como claves la **fecha** y la **variedad de papa**, asignando a cada registro de abastecimiento su correspondiente precio promedio.

Archivo generado: **dataset_unificado_volumen_precios_total.csv**

2. Consolidar_Precios_Volumen_Diesel.ipynb

Sobre el conjunto de datos anterior se incorporó el índice mensual del diésel mediante una unión por fecha. Posteriormente se eliminaron los registros correspondientes a mayo de 2026 debido a que el índice del diésel para dicho mes no se encontraba disponible al momento de la recolección de datos.

Archivo generado: **dataset_papas_con_diesel_hasta_abril_2026.csv**

3. Consolidar_Clima_Precios_Volumen_Diesel.ipynb

Finalmente, se integró la información climática con el conjunto de datos anterior mediante una unión utilizando la fecha y la zona abastecedora como criterios de correspondencia. Durante este proceso se normalizaron nombres de zonas, se verificó la existencia de valores nulos y se eliminaron los registros incompletos.

Como resultado se obtuvo un conjunto de datos comprendido entre el **01/01/2022** y el **03/02/2026**, conformado por **37 482 registros**.

El archivo final generado fue: **Dataset_Final_Modelado.csv**.

ANEXO A : TABLA DE ZONAS

Zona	región	Latitud	Longitud
Abancay	APURIMAC	-13.6339	-72.8814
Acobamba	HUANCAVELICA	-12.8411	-74.5714
Ambo	HUÁNUCO	-10.1303	-76.2047
Andahuaylas	APURIMAC	-13.6556	-73.3878
Angaraes (Lircay)	HUANCAVELICA	-12.9889	-74.7214
Arequipa	AREQUIPA	-16.4090	-71.5375
Huamanga (Ayacucho)	AYACUCHO	-13.1588	-74.2239
Jauja	JUNIN	-11.7778	-75.5000
Antabamba	APURIMAC	-14.3639	-72.8856
Barranca	LIMA	-10.7500	-77.7611
Cajatambo	LIMA	-10.4739	-76.9914
Camana	AREQUIPA	-16.6231	-72.7100

Canete	LIMA	-13.0761	-76.3864
Cangallo	AYACUCHO	-13.6314	-74.1439
Canta	LIMA	-11.4675	-76.6239
Caraveli	AREQUIPA	-15.7725	-73.3661
Caylloma (Chivay)	AREQUIPA	-15.6383	-71.6011
Chanchamayo (La Merced)	JUNÍN	-11.0542	-75.3289
Chincha (Chincha Alta)	ICA	-13.4164	-76.1322
Churcampa	HUANCAVELICA	-12.7419	-74.3886
Concepcion	JUNÍN	-11.9183	-75.3117
Daniel Alcides Carrion (Yanahuanca)	PASCO	-10.4894	-76.5133
Huamalies (Llata)	HUANUCO	-9.5494	-76.8164
Huanca Sancos	AYACUCHO	-13.9186	-74.3333
Huancavelica	HUANCAVELICA	-12.7864	-74.9756
Huancayo	JUNÍN	-12.0653	-75.2048
Huanta	AYACUCHO	-12.9344	-74.2478
Huanuco	HUANUCO	-9.9306	-76.2406
Huaral	LIMA	-11.4958	-77.2078
Huarochari (Matucana)	LIMA	-11.8436	-76.4008
Huaura (Huacho)	LIMA	-11.1086	-77.6050

Huaycabamba (Huacaybamba)	HUANUCO	-9.0436	-76.9536
Huaytara	Huancavelica	-13.6036	-75.3514
Ica	ICA	-14.0678	-75.7286
Julcan	LA LIBERTAD	-8.0417	-78.4906
Junin	JUNIN	-11.1589	-75.9931
La Mar (San Miguel)	AYACUCHO	-13.0125	-73.9811
Lima	LIMA	-12.0464	-77.0428
Lucanas (Puquio)	AYACUCHO	-14.6936	-74.1256
Nazca	ICA	-14.8308	-74.9381
Oyón	LIMA	-10.6694	-76.7714
Oxapampa	PASCO	-10.5775	-75.4017
Pachitea (Panao)	HUÁNUCO	-9.8978	-75.9964
Palpa	ICA	-14.5336	-75.1856
Parinacochas (Coracora)	AYACUCHO	-15.0161	-73.7806
Pasco (Cerro de Pasco)	PASCO	-10.6839	-76.2567
Pisco	ICA	-13.7100	-76.2050
Sanchez Carrion (Huamachuco)	LA LIBERTAD	-7.8147	-78.0486
Santiago De Chuco	LA LIBERTAD	-8.1422	-78.1739
Tarma	JUNÍN	-11.4189	-75.6886

Tayacaja (Pampas)	HUANCAVELICA	-12.3969	-74.8697
Vilcas Huaman	AYACUCHO	-13.6528	-73.9536
Yauli (La Oroya)	JUNÍN	-11.5208	-75.8972
Yauyos	LIMA	-12.4589	-75.9172