

“Algoritmo de Predicción del costo de la papa Blanca en el Mercado Mayorista”

Autor/Autores: Pollo Libia Brillytd Xena, Tinoco Seperak Renzo Sebastian, De los Santos Diaz Josue Jeremy, Vilchez Canaza Giancarlo Edwin.

Resumen- Se propone un modelo de regresión en series temporales para predecir el precio de la Papa Blanca en el Gran Mercado Mayorista de Lima, integrando datos del SISAP, NASA POWER y BCRP (2022–2026). Se evaluaron modelos supervisados bajo validación cronológica, destacando Random Forest como el de mejor desempeño (RMSE: 0.0983, R^2 : 0.759), confirmando la efectividad de enfoques basados en árboles para series agrícolas

1. Introducción

La predicción de precios en mercados agrícolas constituye un problema relevante dentro del análisis de series temporales debido a la alta volatilidad asociada a factores de oferta, demanda y condiciones exógenas. En particular, el Gran Mercado Mayorista de Lima (GMML) actúa como un punto de referencia en la formación diaria de precios de productos agrícolas en el Perú, donde pequeñas variaciones en la oferta pueden generar fluctuaciones significativas en el precio de productos perecibles como la papa.

En este contexto, el comportamiento del precio de la Papa Blanca presenta patrones de dependencia temporal y sensibilidad a variables externas, lo que ha motivado el uso de modelos de aprendizaje automático para su predicción. Estos modelos permiten capturar relaciones no lineales entre variables históricas, climáticas y económicas, mejorando el desempeño frente a enfoques estadísticos tradicionales en problemas de forecasting agrícola (Nayak et al., 2024).

Desde una perspectiva metodológica, el problema se plantea como una tarea de regresión en series temporales con horizonte de predicción de corto plazo, en la cual el objetivo es estimar el precio futuro a partir de información histórica y variables exógenas. Este tipo de formulación es consistente con estudios de predicción en sistemas económicos con alta autocorrelación temporal, donde el comportamiento pasado influye significativamente en los valores futuros.

1.1 Hipótesis y/o preguntas a abordar

¿Cómo puede un modelo de Machine Learning predecir el precio de la papa blanca utilizando datos históricos, factores económicos y variables climáticas para apoyar la toma de decisiones de los comerciantes?

La implementación de un modelo de Machine Learning permitirá predecir de manera eficiente las variaciones en el precio de la papa mediante el análisis de datos históricos, factores económicos y variables climáticas, ayudando a los comerciantes a tomar mejores decisiones de almacenamiento y venta para reducir riesgos económicos y maximizar sus ganancias.

1.2 Objetivos

Objetivo General

- Diseñar y validar un sistema de predicción basado en algoritmos de Machine Learning para estimar las variaciones de costo de la papa en Lima Metropolitana, integrando factores multivariantes que permitan reducir la incertidumbre en la toma de decisiones comerciales.

Objetivos Específicos

- Analizar y preprocesar conjuntos de datos históricos de precios agrícolas, aplicando técnicas de normalización y manejo de valores perdidos para asegurar la calidad de entrada al modelo de ML.
- Implementar y comparar el rendimiento de diversos algoritmos de aprendizaje supervisado, tales como Light Gradient Boosting Machine (LGBM), Random Forest (RF) y Support Vector Regression (SVR), para identificar el núcleo predictivo más robusto.
- Aplicar técnicas de optimización metaheurística para el ajuste de



hiperparámetros de los modelos, buscando minimizar el error cuadrático medio y mejorar la capacidad de generalización del sistema.

2. Trabajos relacionados

La literatura científica contemporánea ha demostrado que la predicción de precios de productos básicos agrícolas requiere de modelos de Machine Learning capaces de capturar relaciones no lineales y dependencias complejas. El análisis se ha desplazado de modelos estadísticos simples hacia el de aprendizaje supervisado multivariante y sistemas híbridos.

En el ámbito de la predicción de tubérculos, el uso de técnicas de Boosting ha tomado relevancia por su alta precisión en datos tabulares. Liu (2025) investiga el uso de Light Gradient Boosting Regression (LGBR) como base para la predicción de precios de la papa. La investigación destaca que, aunque los modelos base son potentes, su rendimiento máximo se alcanza mediante la hibridación con algoritmos metaheurísticos. Específicamente, el uso del Stochastic Paint Optimizer (SPO) y el Population-based Vortex Search Algorithm (PVSA) permite optimizar la tasa de aprendizaje y la profundidad de los árboles, reduciendo drásticamente la tasa de error frente a modelos de regresión lineal. Este enfoque es crucial para la problemática de Lima, donde la volatilidad requiere un ajuste fino de los parámetros del modelo para no caer en el sobreajuste.

La efectividad de los modelos de ML aumenta significativamente cuando se incorporan variables externas al precio histórico. Nayak et al. (2024) compararon diversos algoritmos de Machine Learning, incluyendo Redes Neuronales Artificiales (ANN), Support Vector Regression (SVR), Random Forest Regression (RFR) y XGBoost para predecir precios agrícolas en la India. Su análisis determinó que el rendimiento de algoritmos como XGBoost y SVR mejora sustancialmente al integrar datos de precipitación y temperatura como regresores adicionales. El estudio demuestra que el Machine Learning no solo predice a partir de la tendencia, sino que "entiende" la causalidad climática, lo cual es directamente aplicable a la estacionalidad de la papa en los mercados de Lima, donde el clima andino condiciona la oferta.

Un componente crítico en el desarrollo de modelos de ML para el comercio minorista es la naturaleza de los datos de entrada. Grasmann y Musliu (2026) exploraron el uso de modelos como Random Forest y Elastic Net (EN) para la previsión de ventas de alimentos perecederos. Su contribución más importante al campo del Machine Learning es la integración de "datos de movimiento" y "datos contextuales" (como días festivos o proximidad a eventos logísticos). El estudio resalta que el algoritmo de Random Forest muestra una robustez

excepcional contra el ruido en los datos, superando a menudo a modelos más complejos en situaciones de alta variabilidad. Para el caso de Lima Metropolitana, este enfoque sugiere que el modelo de ML debe alimentarse no solo de precios, sino de factores de movilidad y logística de los centros de abasto.

3. Metodología

Enfoque(s) propuesto:

El presente trabajo aborda la predicción del precio de la Papa Blanca como un problema de regresión en series temporales, mediante un enfoque de aprendizaje supervisado. El objetivo es modelar la relación entre variables históricas, climáticas y económicas para estimar el precio diario en el Gran Mercado Mayorista de Lima .




Figura 3. Flujo de desarrollo del modelo predictivo
Nota. Elaboración Propia

3.1 Recopilación de los Datasets

El conjunto de datos utilizado en el presente estudio fue construido a partir de la integración de tres fuentes principales: el Sistema de Información de Abastecimiento y Precios (SISAP-MIDAGRI), la plataforma NASA POWER y el Banco Central de Reserva del Perú (BCRP). Estas fuentes permiten incorporar variables comerciales, climáticas y económicas necesarias para la modelación del precio de la Papa Blanca en el Gran Mercado Mayorista de Lima.

La integración de los datos se realizó mediante un proceso de alineación temporal y consolidación a frecuencia diaria, garantizando consistencia entre las distintas fuentes durante el periodo de análisis comprendido entre 2022 y 2026. El procedimiento completo de extracción, transformación y preprocesamiento de datos se encuentra documentado en el repositorio del proyecto en GitHub, el cual asegura la reproducibilidad del pipeline.

Como se observa en la Tabla 1, se presenta el dataset final junto con su diccionario de variables. Asimismo, el proceso de construcción y procesamiento de datos se detalla en las Figuras 3, 4 y 5, mientras que la integración final del dataset consolidado se muestra en la Figura 6.



Tabla 1. Diccionario del Dataset Final.

Columna	Tipo de dato	Fuente	Descripción
fecha	Texto/String	SISAP-MIDAG RI	Fecha en formato AAAA-MM-DD del registro del mercado.
precio_promedio_kg	N Numérico (Float)	SISAP-MIDAG RI	Precio promedio diario en Soles por kilogramo en el GMLL.
volumen	N Numérico (Float)	SISAP-MIDAG RI	Toneladas totales de papa que ingresaron al mercado ese día.
variedad	C Categoría (Texto)	SISAP-MIDAG RI	Nombre de la variedad de papa (Blanca, Yungay, Única, etc.).
zona	C Categoría (Texto)	SISAP-MIDAG RI	Provincia de origen geográfico del cargamento agrícola.
región	C Categoría (Texto)	SISAP-MIDAG RI	Región o Departamento de origen geográfico del cargamento agrícola.
T2M_MAX	N Numérico (Float)	NASA POWER	Temperatura máxima registrada a 2 metros del suelo (°C) en las zonas de cultivo asociadas.
T2M	N Numérico (Float)	NASA POWER	Temperatura promedio registrada a 2 metros del suelo (°C) en las zonas de cultivo asociadas.
T2M_MIN	N Numérico (Float)	NASA POWER	Temperatura mínima registrada a 2 metros del suelo (°C) en las zonas de cultivo.
PRECOTCORR / IMERG_PRECOT / lluvia_hoy	N Numérico / Binario	NASA POWER	Precipitaciones totales corregidas del día.
indice_precio_diesel	N Numérico (Float)	BCRP	Índice mensual del costo del combustible diésel a nivel nacional. (S/)

Nota. Elaboración Propia




Figura 3. Esquema de procesamiento de datos del BCRP.




Figura 4. Esquema de procesamiento de datos del SISAP-V2.




Figura 5. Esquema de procesamiento de datos de NASA-POWER.




Figura 6. Esquema de construcción final del Dataset.

3.2 Justificación de elección del tipo de papa a analizar

Con el propósito de seleccionar la variedad de papa más adecuada para el desarrollo del modelo predictivo, se realizó un análisis exploratorio considerando criterios estadísticos y temporales. En primer lugar, se evaluó la distribución de los datos por variedad, observándose que la **papa blanca** concentra la mayor cantidad de registros históricos y presenta un coeficiente de variación comparable con las variedades más representativas, lo que evidencia una adecuada estabilidad en sus precios. Posteriormente, la evaluación de la autocorrelación mostró que esta variedad mantiene una persistencia significativa del precio tanto a nivel diario como semanal, indicando que el comportamiento pasado constituye una fuente de información relevante para la predicción. Además, al comparar las tres variedades con mayor número de muestras (blanca, Yungay y Canchan), se observó que la papa blanca presenta una respuesta consistente frente a variables exógenas, como el precio del diésel, la lluvia y las heladas. Finalmente, el análisis de representatividad confirmó que esta variedad posee la mayor proporción de observaciones dentro del conjunto de datos. En conjunto, estos resultados justifican la selección de la papa blanca como la variedad más adecuada para el desarrollo del modelo de Machine Learning.

```
==== OUTPUT DEL PROMPT 3: MATRIZ DE SELECCIÓN DE LA MUESTRA PROCESADA ====
Variedad de Papa  Muestra (N)  Volumen (t)  Participación (%)  CV (Precio)  Sesgo (Skewness)  Curtosis
PAPA BLANCA      18954      2136444.0    74.21             0.3588       1.2273            0.9349
PAPA YUNGAY      5264       209150.0     7.26              0.3756       1.1881            0.4715
PAPA CANCHAN     3545       146553.0     5.89              0.2813       0.5858            -0.8087
PAPA AMARILLA    3049       140857.0     4.80              0.3396       1.0656            0.8070
PAPA UNICA       3239       139416.0     4.84              0.3243       0.1542            -0.4147
PAPA COLOR       1687       51128.0      1.78              0.2516       0.3527            0.1187
PAPA HUAYRO     1460       50876.0      1.77              0.3694       2.1814            5.0993
PAPA PERUMITA    211        3592.0       0.12              0.3632       0.8741            -0.0751
PAPA NEGRA ANDINA 49         670.0        0.02              0.3866       0.2889            -1.3632
```

Figura 7. Análisis general de participación y variación de precio

3.3 Preprocesamiento y estructuración de datos



El proceso de preprocesamiento tuvo como objetivo obtener un conjunto de datos consistente y adecuado para el entrenamiento de los modelos de Machine Learning. En primer lugar, se realizó una revisión de los valores nulos mediante el cálculo de su porcentaje por columna y su visualización a través de un mapa de calor, verificando la calidad del conjunto de datos. Luego una primera inspección al mapa de correlación para ver su estado actual **ver figura 8**.

Posteriormente, se eliminaron las variables región y T2M, debido a que no aportan información relevante para el modelo o presentaban redundancia con otras variables disponibles.

A continuación, se filtró el conjunto de datos para conservar únicamente los registros correspondientes a la papa blanca, variedad seleccionada en la etapa de análisis exploratorio. Una vez realizado el filtrado, la variable variedad fue eliminada para convertirse en una característica constante y, por tanto, sin capacidad predictiva.

Posteriormente, la variable categórica zona fue transformada mediante la técnica **One-Hot Encoding**, permitiendo que pudiera ser utilizada por los algoritmos de aprendizaje automático. Asimismo, la variable **fecha** fue convertida a una representación cíclica utilizando las funciones seno y coseno, con el propósito de preservar la naturaleza periódica del calendario y capturar patrones estacionales. Finalmente, se verificó la correlación entre las variables numéricas mediante una matriz de correlación y se generó el conjunto de datos preprocesado que fue utilizado en la etapa de entrenamiento de los modelos **ver figura 10**.

Figura 9. Mapa de correlación de variables antes del preprocesamiento




Figura 10. Mapa de correlación de variables resultado del Preprocesamiento

Nota: Para identificar variables redundantes, se construyó una matriz de correlación y se estableció un umbral de 0.87 como criterio de selección. Este valor permite detectar pares de variables con una correlación muy alta, las cuales aportan información similar y pueden generar problemas de multicolinealidad

3.4 División de datos en entrenamiento

La partición del conjunto de datos se realizó bajo un enfoque estrictamente cronológico, evitando cualquier forma de muestreo aleatorio que pudiera generar fuga de información futura hacia el conjunto de entrenamiento. Se utilizó el 80% inicial de las observaciones como entrenamiento (2022-04-01 a 2025-04-19, 1115 observaciones) y el 20% final como prueba (2025-04-20 a 2026-01-23, 279 observaciones), simulando un escenario real de predicción fuera de muestra. Adicionalmente, se empleó validación cruzada TimeSeriesSplit de 5 pliegues sobre el bloque de entrenamiento, generando particiones secuenciales que respetan el orden temporal, a diferencia de K-Fold aleatorio.

3.5 Modelos Propuestos

Se implementaron cinco modelos de regresión supervisada para el horizonte de 7 días: un baseline de persistencia (Naive_t), Ridge (regresión lineal regularizada L2), Random Forest Regressor (ensamble de bagging, robusto frente a no linealidades), LightGBM (boosting por árboles de gradiente, eficiente en datos tabulares) y SVR con kernel RBF (modelo de margen máximo, sensible a escala). Este conjunto permitió contrastar métodos lineales, de bagging, de boosting y de kernel bajo el mismo esquema de validación.


3.6 Configuración Experimental



La variable objetivo fue el precio promedio diario de la Papa Blanca (S/ por kg). Para estabilizar el aprendizaje, los modelos se entrenaron sobre el cambio de precio $\Delta y = \text{precio}(t+7) - \text{precio}(t)$, y el precio pronosticado se reconstruyó como $\text{precio}(t) + \Delta y_{\text{predicho}}$. Las variables de entrada incluyeron rezagos (1, 2, 3, 7, 14, 30, 60, 90 días), medias móviles (3, 7, 14, 30, 60, 90 días), desviaciones móviles (7, 30 días), diferencias de precio, variables calendario (codificación cíclica seno/coseno), volumen, participaciones regionales rezagadas, clima con desfase y el índice de diésel. Los hiperparámetros se ajustaron con GridSearchCV y TimeSeriesSplit de 5 pliegues, optimizando el RMSE negativo: Ridge sobre $\alpha \in \{0.1, 1, 5, 10, 50, 100\}$ (óptimo: 100); Random Forest sobre $\text{max_depth} \in \{8, \text{None}\}$ y $\text{min_samples_leaf} \in \{2, 5\}$ (óptimo: $\text{max_depth}=8$, $\text{min_samples_leaf}=2$); LightGBM sobre $\text{num_leaves} \in \{15, 31\}$ y $\text{learning_rate} \in \{0.05, 0.1\}$ (óptimo: $\text{num_leaves}=31$, $\text{learning_rate}=0.05$); SVR-RBF sobre $C \in \{1, 10\}$ y $\text{epsilon} \in \{0.01, 0.05\}$ (óptimo: $C=1$, $\text{epsilon}=0.05$).

3.7 Análisis de importancia de variables

Con el fin de interpretar el comportamiento del modelo de ensamble y de identificar qué grupos de variables concentran mayor peso en la predicción del precio de la Papa Blanca, se calculó la importancia de variables del Random Forest optimizado ($\text{max_depth}=8$, $\text{min_samples_leaf}=2$, $n_{\text{estimators}}=300$), mediante el atributo `feature_importances_`, basado en la reducción media de impureza (Mean Decrease in Impurity, MDI) aportada por cada variable en las particiones del árbol.



importance	
day_id	0.130762
precio_rol60	0.123807
precio_delta14	0.062804
precio_delta7	0.057205
precio_lag90	0.056419
precio_rol30	0.052642
fecha_cos	0.048710
precio	0.040429
fecha_sin	0.037924
precio_lag60	0.036922

El patrón general muestra que el modelo concentra la mayor parte de su capacidad predictiva en variables autorregresivas y de tendencia de mediano-largo plazo: la media móvil de 60 días (`precio_rol60`), los rezagos de 60 y 90 días, y las diferencias de precio a 7 y 14 días explican, en conjunto, más del 35% de la importancia total. Las variables de calendario cíclico (`fecha_sin`, `fecha_cos`) también aparecen entre las más relevantes, lo que es consistente con la existencia de un componente estacional en el abastecimiento y precio de la papa. En contraste, las variables climáticas y económicas rezagadas (`diesel_lag7`, `lluvia_lag14`, `helada_lag30`) no figuran entre las diez más importantes, lo que sugiere que, bajo el criterio de partición por impureza del Random Forest, su aporte marginal es menor al de la dinámica propia del precio, al menos con la parametrización de rezagos utilizada.

Es necesario matizar el resultado más llamativo de la tabla: `day_id` —un índice entero prácticamente único por observación, construido en la Sección 1.2 para reconstruir el orden cronológico— aparece como la variable de mayor importancia. Esto debe interpretarse con cautela por dos razones. Primero, la importancia por impureza (MDI) tiende a sobreestimar variables continuas de alta cardinalidad, ya que estas ofrecen más puntos de corte posibles para reducir el error en cada nodo; esta es una limitación documentada del método por defecto de `scikit-learn`, no necesariamente evidencia de que el tiempo cronológico explique el precio. Segundo, `day_id` actúa como una tendencia lineal encubierta: al ser monótonamente creciente, el árbol puede usarlo para memorizar el orden temporal del conjunto de entrenamiento en lugar de aprender una relación causal generalizable. Como se discute en la sección de Resultados, este hallazgo está directamente relacionado con la falla de generalización del Random Forest en el conjunto de prueba, por lo que se recomienda —como trabajo futuro— repetir este análisis con importancia por permutación (`permutation importance`) y evaluar el retiro o la transformación de `day_id` en una codificación puramente estacional (sin componente de tendencia).

3.8 Entrenamiento y selección del modelo óptimo

El entrenamiento se organizó como una búsqueda de hiperparámetros supervisada por validación cruzada temporal, seguida de una evaluación final sobre el conjunto de prueba, sin retroalimentación entre ambas etapas. Sobre el bloque de entrenamiento (1,115 obs., 2022-04-01 a 2025-04-19) se ajustó cada modelo mediante GridSearchCV con TimeSeriesSplit de 5 pliegues y `neg_root_mean_squared_error` como criterio. La variable objetivo fue el cambio de precio a 7 días ($\Delta y = \text{precio}(t+7) - \text{precio}(t)$), lo que reduce la no estacionariedad y evita que el modelo aprenda solo el nivel general del precio; las predicciones se reconvirtieron luego a escala original con $\text{precio_pred}(t+7) = \text{precio}(t) + \Delta y_pred$.

Se entrenaron cinco enfoques: Naive_t ($\Delta y = 0$) como referencia mínima; Ridge y SVR-RBF dentro de un Pipeline con StandardScaler por su sensibilidad a la escala; y Random Forest y LightGBM, que no requirieron escalamiento.

La selección del modelo óptimo se basó en el RMSE del conjunto de prueba, no en el de validación interna, para medir la generalización real. Ridge obtuvo el menor error (RMSE = 0.2132), muy cerca del baseline Naive_t (0.2146). Random Forest y LightGBM generalizaron peor: la importancia de variables (sección 3.7) mostró que Random Forest se apoyó en `day_id`, un índice temporal fuera de rango en prueba, lo que explica su caída de desempeño.

	Modelo	MAE	RMSE	MAPE	sMAPE	R2
0	Ridge	0.150497	0.213173	10.910821	10.997086	0.563709
1	Naive_t	0.142007	0.214648	10.312430	9.970413	0.557651
2	SVR-RBF	0.172139	0.251272	12.517264	12.960589	0.393825
3	LightGBM	0.251234	0.293069	19.497349	17.373236	0.175386
4	Random Forest	0.415895	0.453882	32.843450	27.467914	-0.977867

Tabla 4. Espacio de búsqueda e hiperparámetros óptimos por modelo

Ridge	alpha: [0.1, 1, 5, 10, 50, 100]	alpha = 100
Random Forest	n_estimators: [300]; max_depth: [8, None]; min_samples_leaf: [2, 5]	max_depth=8, min_samples_leaf=2, n_estimators=300
LightGBM	n_estimators: [300]; num_leaves: [15, 31]; learning_rate: [0.05, 0.1]	learning_rate=0.05, num_leaves=31, n_estimators=300
SVR-RBF	C: [1, 10]; epsilon: [0.01, 0.05]; gamma: ['scale']	C=1, epsilon=0.05, gamma='scale'

Dos resultados de esta búsqueda anticipan lo observado más adelante en el desempeño de prueba: Ridge convergió al valor de regularización más alto de toda la grilla (alpha=100), y SVR convergió al valor de penalización más bajo (C=1), ambos ajustes indicativos de una preferencia del proceso de validación cruzada por soluciones conservadoras, cercanas a una relación casi lineal/cercana a cero para el delta de precio, en lugar de ajustes agresivos a la variabilidad de entrenamiento.

El modelo óptimo se definió, en primera instancia, por el menor RMSE sobre el conjunto de prueba cronológico (criterio de regresión de precio). Bajo este criterio, Ridge resultó ser el modelo seleccionado (RMSE = 0.2132 S//kg), aunque —como se discute en la sección de Resultados— su margen de mejora frente al baseline de persistencia fue marginal. De manera complementaria, se definió también un mejor modelo direccional, elegido por el F1 de la clase "sube", ya que el objetivo de regresión (minimizar el error de precio) no garantiza que el modelo sea útil para anticipar la dirección del cambio, que es relevante para decisiones comerciales. Ambos criterios no coincidieron en el mismo modelo, lo cual se analiza en detalle más adelante.

Modelo	Hiperparámetros explorados	Mejor combinación (CV)
--------	----------------------------	------------------------

4. Experimentación y Resultados

■ Setup experimental:

Datos utilizados. Se partió de **Dataset_Preprocesado_Papa_Blanca.csv** (18,954 obs. zona × día, 61 columnas). Al estar la fecha ya codificada cíclicamente, el orden cronológico se reconstruyó agrupando filas con la misma codificación, obteniendo una serie diaria de 1,491 días (2022-01-01 a 2026-01-30). En la agregación diaria el precio se tomó como valor único de mercado, el volumen se sumó, el clima se promedió entre zonas, y se calculó la participación de volumen de las cinco zonas de mayor abastecimiento (Huánuco, Huancayo, Tarma, Huamanga y Arequipa). Sobre esta serie se construyeron rezagos (1–90 días), medias y desviaciones móviles, diferencias de precio, rezagos de volumen, y rezagos de clima/diésel/participación regional (7, 14 y 30 días según la variable), bajo el criterio de que su efecto no es inmediato. Para el horizonte de 7 días esto produjo 41 variables predictoras y 1,394 observaciones utilizables.

Métricas de evaluación. Para la tarea de regresión se emplearon MAE, RMSE, MAPE, sMAPE y R^2 , calculadas sobre el precio reconstruido en soles por kilogramo. Como evaluación complementaria orientada a la decisión comercial, se definió la tarea binaria "sube" ($\text{precio}(t+7) > \text{precio}(t)$), evaluada con exactitud, precisión, recall y F1 sobre la clase positiva, y visualizada mediante matriz de confusión.

Experimentos realizados. (1) Comparación de los cinco modelos en el horizonte de 7 días, con ajuste de hiperparámetros por GridSearchCV + TimeSeriesSplit (5 pliegues) y evaluación final en el conjunto de prueba cronológico (20% más reciente, 279 observaciones). (2) Análisis de la distribución de RMSE por pliegue de validación cruzada, para observar la estabilidad de cada modelo antes de tocar el conjunto de prueba. (3) Evaluación direccional derivada de las mismas predicciones de regresión. (4) Dos estrategias de mejora direccional: calibración del umbral de decisión sobre Δy_{pred} (búsqueda por validación cruzada) y un clasificador dedicado (RandomForestClassifier, con `class_weight='balanced'`) entrenado directamente sobre la etiqueta binaria. (5) Importancia de variables del Random Forest (sección 3.7). (6) Un escenario complementario con horizonte de 1 día, para contrastar el aporte de los modelos frente a una autocorrelación mucho más fuerte.

- **¿El enfoque desarrollado resuelve siempre el problema?** No de manera consistente. En el horizonte de 7 días solo Ridge logró un RMSE ligeramente menor que el baseline de persistencia; Random Forest, LightGBM y SVR


quedaron por debajo del baseline. En el horizonte de 1 día ningún modelo superó de forma clara al baseline en MAE, MAPE o sMAPE.

- **¿Qué tan eficientemente lo resuelven?** En términos de costo de búsqueda, Ridge exploró la grilla más amplia (6 combinaciones × 5 pliegues = 30 ajustes) por ser el modelo más económico de entrenar; Random Forest, LightGBM y SVR se limitaron a grillas de 4 combinaciones (20 ajustes) dado el mayor costo por ajuste de los ensambles de 300 árboles y del kernel RBF sobre ~1,100 observaciones de entrenamiento. No se registró tiempo de cómputo exacto en el cuadernillo, por lo que este punto queda como una estimación cualitativa basada en el tamaño de la grilla y la naturaleza de cada algoritmo.
- **¿Cuál es el desempeño comparado con otros modelos o técnicas de referencia?** Se detalla en
- **¿Cómo influyen los parámetros del enfoque en su desempeño?** La validación cruzada favoreció configuraciones conservadoras (Ridge con $\alpha=100$, SVR con $C=1$), es decir, modelos que se alejan poco de una predicción cercana al delta promedio de entrenamiento. Random Forest, en cambio, con una profundidad moderada (`max_depth=8`) mostró buen desempeño en validación cruzada pero una caída abrupta en el conjunto de prueba, lo que se analiza a continuación.

■ Resultados y Discusión:

Resultados de regresión — horizonte de 7 días

	Modelo	MAE	RMSE	MAPE	sMAPE	R2
0	Ridge	0.0506	0.1005	3.48	3.46	0.905
1	Naive_t	0.0463	0.1014	3.15	3.12	0.903
2	SVR-RBF	0.0594	0.1045	4.21	4.17	0.898
3	Random Forest	0.0578	0.1053	4.09	4.00	0.896
4	LightGBM	0.0669	0.1114	4.78	4.67	0.884



Ridge obtuvo el menor RMSE (0.2132 frente a 0.2146 del baseline), pero la diferencia —menos de 1%— no



es sustancial, y en MAE, MAPE y sMAPE el baseline de persistencia fue en realidad ligeramente mejor. En conjunto, ambos modelos son prácticamente indistinguibles en desempeño, con un R^2 moderado (≈ 0.56) que indica que gran parte, pero no toda, la variabilidad del precio a 7 días es explicada por la información disponible hasta el momento t . Los residuos del modelo seleccionado (Ridge) tuvieron media de 0.0181 S//kg y desviación estándar de 0.2124, es decir, un sesgo pequeño hacia la subestimación y una dispersión consistente con el RMSE reportado, sin evidencia de un sesgo sistemático severo.



El hallazgo más relevante de esta tabla es el deterioro progresivo de los modelos más complejos: SVR pierde buena parte de su capacidad explicativa ($R^2=0.394$), LightGBM cae a $R^2=0.175$, y Random Forest colapsa con R^2 negativo (-0.978), es decir, peor que predecir simplemente el promedio del conjunto de prueba. Esto contrasta con el comportamiento de Random Forest en validación cruzada (ver siguiente apartado), donde fue de los modelos más competitivos.

	Naive_t	Ridge	Random Forest	SVR-RBF	LightGBM
0	0.128273	0.185794	0.131671	0.137139	0.145444
1	0.166045	0.215542	0.163339	0.167855	0.184682
2	0.154106	0.170802	0.161739	0.172608	0.202237
3	0.125745	0.142518	0.144242	0.149144	0.134650
4	0.252331	0.286806	0.274087	0.308921	0.262170

Este resultado exhibe una discrepancia relevante para la interpretación general del experimento: en validación cruzada, **Ridge fue sistemáticamente el peor modelo de los cinco en cada uno de los cinco pliegues**, mientras que Random Forest ocupó el segundo lugar, muy cerca del baseline. Sin embargo, en el conjunto de prueba final la situación se invierte casi por completo: Ridge pasa a ser el "mejor" modelo y Random Forest se convierte en el peor por un margen amplio. Esta inversión de ranking entre validación cruzada y prueba final sugiere la presencia de un cambio de régimen (*distribution shift*) entre el periodo usado para entrenar/validar (2022–2025) y el periodo de prueba (abril 2025–enero 2026), y es consistente con la hipótesis planteada en la Sección 3.7: si Random Forest apoya gran parte de su predicción en variables de tendencia como `day_id` y `precio_rol160`, su desempeño se degrada al proyectar fuera del rango de valores observado en entrenamiento, una limitación conocida de los modelos basados en árboles, que no pueden extrapolar más allá de los valores de las hojas aprendidas. Este resultado es, en sí mismo, una conclusión metodológica relevante: ni la validación cruzada ni una única partición de prueba, por separado, son suficientes para garantizar la elección de un modelo robusto en un problema con posible cambio de régimen; sería recomendable, en trabajo

futuro, emplear un esquema de *backtesting* con múltiples ventanas de prueba.

Mejor modelo por RMSE (regresión): Ridge		Mejor modelo por F1_sube (dirección): LightGBM			
	Modelo	Acierto_direccional	Precision_sube	Recall_sube	F1_sube
0	LightGBM	0.419	0.409	1.000	0.580
1	Random Forest	0.401	0.401	1.000	0.573
2	SVR-RBF	0.577	0.462	0.321	0.379
3	Ridge	0.523	0.376	0.286	0.325
4	Naive_t	0.599	0.000	0.000	0.000



Esta tabla requiere una lectura cuidadosa antes de declarar un "ganador". LightGBM y Random Forest presentan el F1 más alto, pero su *recall* de 1.000 revela que, en la práctica, ambos modelos predicen "sube" para el 100% de las observaciones de prueba; su precisión (≈ 0.40 – 0.41) coincide, de hecho, con la proporción real de días en que el precio subió ($\sim 40\%$ del conjunto de prueba). En otras palabras, se trata de clasificadores degenerados que ignoran

las variables de entrada y replican la clase mayoritaria de "subida" observada en entrenamiento, por lo que su F1 relativamente alto no refleja una capacidad predictiva genuina. En el otro extremo, Naive_t predice "no sube" siempre ($F1=0$ por definición del baseline), lo que explica su exactitud aparentemente alta (0.599): simplemente coincide con la clase mayoritaria real del periodo de prueba ("no sube", ~60% de los casos). Ridge y SVR, aunque con F1 más bajo (0.325 y 0.379), son los únicos modelos cuyo *recall* está por debajo de 1 y por encima de 0, es decir, los únicos que muestran algún poder discriminante real entre ambas clases, aunque modesto.

	Estrategia	Acierto	Precision_sube	Recall_sube	F1_sube
0	LightGBM (umbral=0, derivado de regresión)	0.419	0.409	1.000	0.580
1	LightGBM (umbral calibrado)	0.412	0.406	1.000	0.577
2	Clasificador dedicado (RandomForestClassifier)	0.577	0.458	0.295	0.359

La calibración del umbral de decisión de LightGBM no mejoró su desempeño ($F1 = 0.577$ frente a 0.580 con umbral 0), evidenciando un sesgo del modelo hacia predecir casi siempre que el precio subirá. En contraste, RandomForestClassifier, aunque obtuvo un F1 menor (0.359), sí diferenció ambas clases, por lo que se recomienda como la mejor alternativa para predecir la dirección del precio. Al reducir el horizonte de predicción de 7 a 1 día, todos los modelos mejoraron (R^2 entre 0.88 y 0.91), pero Ridge volvió a obtener el menor RMSE, mientras que el baseline de persistencia siguió siendo superior en varias métricas. En conjunto, ningún modelo superó de forma consistente al baseline, ni para 1 ni para 7 días.

5. Conclusión

El estudio evaluó si un modelo de Machine Learning puede predecir el precio de la Papa Blanca usando datos históricos, económicos y climáticos. Los resultados muestran que los modelos capturan parcialmente la dinámica del precio, aunque con un desempeño menor al esperado. Ridge obtuvo la mejor capacidad de generalización (RMSE = 0.2100 S//kg, MAPE = 9.98%, $R^2 = 0.5901$), superando ligeramente al Baseline Naive y a Random Forest, LightGBM y SVR-RBF. Además, Random Forest no reprodujo el rendimiento reportado inicialmente ($R^2 = 0.4742$ frente al 0.759 esperado), evidenciando sobreajuste. Por otro lado, LightGBM fue el mejor para predecir la dirección del cambio de precio a 7 días, siendo más útil para decisiones de venta o almacenamiento.

6. Sugerencias de trabajos futuros

- Revisar y corregir la reproducibilidad del pipeline: documentar exactamente qué archivo, versión de librerías y semillas aleatorias generaron cualquier métrica reportada, evitando discrepancias como la observada entre el RMSE/ R^2 informado originalmente y el obtenido al ejecutar el código sobre el dataset entregado.
- Aplicar optimización de hiperparámetros (búsqueda en grilla, aleatoria o bayesiana) a Random Forest y LightGBM, con regularización más fuerte (profundidad máxima, mínimo de muestras por hoja, submuestreo) para reducir el sobreajuste evidenciado entre validación cruzada y prueba

7. Implicancias éticas

El presente estudio implicó el uso de datos provenientes de fuentes públicas y agregadas, por lo que no se trabajó con información personal identificable. Sin embargo, al escalar el modelo hacia aplicaciones reales de predicción de precios agrícolas, pueden surgir implicancias éticas relacionadas con la toma de decisiones automatizada en mercados sensibles.

En particular, un modelo de predicción de precios podría influir indirectamente en estrategias de compra, almacenamiento y especulación de comerciantes, lo que podría generar asimetrías de información entre actores del mercado. Asimismo, el uso de variables económicas y climáticas podría inducir sesgos si los datos presentan subrepresentación de ciertas regiones o condiciones extremas.


Para mitigar estos riesgos, se recomienda mantener transparencia en el uso del modelo, validar periódicamente los datos de entrada y evitar su uso como única fuente de decisión comercial.

8. Link del repositorio del trabajo

<https://github.com/GiancaVc12/Inteligencia-Artificial>

9. Declaración de contribución de cada integrante

Pollo B.: recolección de datos, construcción del dataset y apoyo en el preprocesamiento.



Tinoco R.: implementación de modelos de Machine Learning y validación experimental.

De los Santos J.: análisis de variables, visualización de resultados y métricas de evaluación.

Vilchez G.: redacción del informe, estructura del paper, revisión metodológica de selección categórica de la papa y evaluación de modelos de entrenamiento..

10. Declaración de uso de IA

Se utilizó asistencia de IA para organizar el informe, consolidar la redacción, proponer la estructura de evaluación, y redactar comparaciones con la literatura. Los resultados numéricos reportados no fueron inventados: se calcularon ejecutando un pipeline de Python sobre Dataset_Final_Modelado.csv.

La IA también se empleó para revisar coherencia con los criterios de la segunda parte, las recomendaciones recibidas por los JP's para la categorización de la papa a evaluar y los materiales del curso. La responsabilidad final de validar el contenido, revisar el código, verificar citas y defender las decisiones metodológicas corresponde al equipo autor.

11. Referencias

- [1]. Grasmann, L., & Musliu, N. (2026). Improvements of Machine Learning forecasting for perishable food sales in real-world grocers. *Machine Learning with Applications*, 24(100885). <https://doi.org/10.1016/j.mlwa.2026.100885>
- [2]. Liu, L. (2025). Hybrid Machine Learning Models For Optimized Potato Price Prediction. *Journal of Applied Science and Engineering*, 29(5), 1123-1138. [http://dx.doi.org/10.6180/jase.202605_29\(5\).0010](http://dx.doi.org/10.6180/jase.202605_29(5).0010)
- [3]. Nayak, G. H. H., Alam, M. W., Singh, K. N., Avinash, G., Kumar, R. R., Ray, M., & Deb, C. K. (2024). Exogenous variable driven deep learning models for improved price forecasting of TOP crops in India. *Scientific Reports*, 14(17203). <https://doi.org/10.1038/s41598-024-68040-3>

Nota importante:

Figuras y tablas

- Cada figura debe ser leída y comprendida sin necesidad de recurrir a la descripción a lo largo del texto.
- Todos los símbolos usados deben ser explicados en la leyenda